



DEPARTAMENTO  
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

# TP 1: Técnicas Algorítmicas

23 de Abril, 2023

Algoritmos y Estructuras de Datos III

Integrante	LU	Correo electrónico
Zaid, Pablo	869/21	pablozaid2002@gmail.com
Arienti, Federico	316/21	fa.arianti@gmail.com



**Facultad de Ciencias Exactas y Naturales**

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (++54 +11) 4576-3300

<http://www.exactas.uba.ar>

## RESUMEN

Una estrategia *golosa* —o *greedy*— es una estrategia de resolución de problemas, por lo general de optimización, que aprovecha las propiedades intrínsecas a una solución óptima para resolver un problema de manera correcta y computacionalmente eficiente. En relación a la estrategia de *programación dinámica*, el método se basa<sup>1</sup> en la aplicación de la propiedad de *subestructura óptima*<sup>2</sup>: una solución óptima a un problema incorpora soluciones óptimas a subproblemas relacionados. Sin embargo, a diferencia de esta estrategia, los algoritmos *greedy* obtienen una solución por medio de decisiones que “*contemplan la información inmediatamente disponible, sin preocuparse por los efectos que estas decisiones puedan tener en el futuro*”<sup>3</sup>. Un comportamiento que requiere que el problema tenga la propiedad de *selección golosa*: una solución globalmente óptima se puede obtener a partir de decisiones localmente óptimas.

El siguiente informe evalúa la aplicación del método sobre el problema de la *selección de actividades*, que se enmarca dentro del más general *problema de la fiesta*. Además, evalúa la eficiencia del algoritmo resultante de manera empírica.

Palabras clave: *Algoritmos golosos, estrategias algorítmicas, selección de actividades.*

## CONTENIDOS

1. El problema de la selección de actividades	2
1.1. Demostración de la propiedad de subestructura óptima	2
1.2. Demostración de la propiedad de selección golosa	2
1.3. El algoritmo	3
1.4. Complejidad temporal y espacial	3
2. Evaluación empírica	4
2.1. Instancias de interés	5

---

<sup>1</sup>Ver Thomas H. Cormen; Charles E. Leiserson; Ronald L. Rivest y Clifford Stein. Introduction to algorithms. 2009. Sección 16.2: *Elements of a greedy strategy*.

<sup>2</sup>No todo problema tiene esta propiedad y no todo problema que la posee tiene una solución *greedy*.

<sup>3</sup>Ver Gilles Brassard y Paul Bratley. Fundamentals of Algorithmics. 1995. Capítulo 6: *Greedy Algorithms*.

## 1. EL PROBLEMA DE LA SELECCIÓN DE ACTIVIDADES

El problema de la selección de actividades que consideraremos tiene la siguiente premisa. Dado un conjunto

$$A := \{a_1 \dots a_n\}$$

de actividades disponibles, donde, para todo  $1 \leq i \leq n$ , la actividad  $a_i$  se representa por el intervalo  $[s_i, t_i)$  —que corresponde, respectivamente, al tiempo de inicio y finalización de la actividad—, queremos encontrar un subconjunto de  $A$  que nos permita realizar la mayor cantidad de actividades posibles.

En esto, queremos elegir las actividades con la restricción que, para todo par de actividades  $a_i$  y  $a_j$  seleccionadas,  $1 \leq i, j \leq n$ ,  $a_i$  y  $a_j$  no se solapen en el tiempo. Es decir,  $s_i \geq t_j$  o  $s_j \geq t_i$ . Por ejemplo, si

$$A := \{[1, 3), [1, 4), [3, 6), [4, 7), [7, 8)\}$$

luego algunas soluciones óptimas son  $\{[1, 3), [3, 6), [7, 8)\}$  y  $\{[1, 4), [4, 7), [7, 8)\}$ .

Como condición extra, limitaremos el tiempo de la actividad  $a_i$ , para todo  $1 \leq i \leq n$ , de manera tal que  $1 \leq s_i < t_i \leq 2n$ .

**1.1. Demostración de la propiedad de subestructura óptima.** Como preámbulo a la aplicación de una estrategia *golosa* para resolver el problema, veamos primero que el problema tiene la propiedad de *subestructura óptima*.

*Demostración.* Consideremos una solución óptima  $S \subset A$  que contiene, sin pérdida de generalidad, a alguna actividad  $a_i \in A$  para  $1 \leq i \leq n$ . Luego, podemos particionar tanto a  $S$  como a  $A$  entre aquellas actividades que terminan antes que comience  $a_i$ :  $S_{<i}$  y  $A_{<i}$ ; y aquellas que comienzan después de que termine  $a_i$ :  $S_{>i}$  y  $A_{>i}$ .

Si estas particiones de  $S$  no son, correspondientemente, óptimas para las particiones de  $A$ , entonces existe algún subconjunto de actividades  $S'_{<i} \subset A_{<i}$  que tiene un tamaño mayor que la partición  $S_{<i}$  que consideramos y, de igual manera, existe una solución mayor  $S'_{>i}$  para el subconjunto de actividades  $A_{>i}$ .

Sigue entonces que  $S$  no es óptima, ya que podemos formar una solución mejor si consideramos  $S'_{<i} \cup \{a_i\} \cup S'_{>i}$ , lo que es un absurdo.  $\square$

Luego, estamos en condiciones de evaluar el problema dentro del marco teórico de la *programación dinámica*<sup>4</sup>. La siguiente demostración prueba que, además, podemos alcanzar un óptimo por medio de decisiones locales.

**1.2. Demostración de la propiedad de selección golosa.** Consideremos ahora la siguiente estrategia *golosa*: elegir la actividad que finalice primero, de entre todas las actividades que sigan disponibles. Vamos a demostrar que esta estrategia es óptima.

*Demostración.* Notemos primero que, si una solución parcial  $B_1 \dots B_i$  de actividades seleccionadas —que brinde un algoritmo goloso que implemente esta estrategia— se puede extender a una solución óptima, para todo  $0 \leq i \leq n$ , entonces la estrategia es óptima. Lo demostraremos por inducción.

---

<sup>4</sup>De seguir este camino, deberíamos demostrar, también, que el problema cuenta con la propiedad de *solapamiento de subproblemas*.

Para el caso base,  $i = 0$ , el algoritmo todavía no eligió ninguna actividad. Luego, podemos extender la solución a una solución óptima de manera trivial.

Supongamos ahora, para  $i > 0$ , que tenemos una solución parcial  $B_1 \dots B_i$  de actividades elegidas por nuestro algoritmo que se puede extender a una solución óptima

$$B_1 \dots B_i, C_{i+1} \dots C_j$$

donde  $j \leq n$  y, sin pérdida de generalidad, vamos a suponer que la secuencia de actividades sin solapamiento  $C_{i+1} \dots C_j$  está ordenada por tiempo de finalización.

Notar que, por nuestro método de selección,  $B_1 \dots B_i$  también debe estar ordenado de la misma manera. Luego, todas las actividades  $C_{i+1} \dots C_j$  deben empezar después de que termine  $B_i$  para que la extensión sea válida. Si no, habría solapamientos, ya que, por definición de la estrategia, deben terminar después que  $B_i$ .

Consideremos ahora la solución parcial golosa  $B_1 \dots B_{i+1}$ , donde —por el método de selección—  $B_{i+1}$  es la actividad cuyo momento final ocurre antes entre todas las actividades restantes y no se solapa con las actividades ya seleccionadas.

Como  $B_{i+1}$  debe terminar antes que  $C_{i+1}$  o  $B_{i+1} = C_{i+1}$ , entonces  $B_{i+1}$  no puede solaparse con ninguna actividad  $C_{i+2} \dots C_j$ . Esto se debe a que  $C_{i+1}$  no lo hacía y, por hipótesis inductiva, es la actividad que termina antes en la extensión. Luego,  $B_1 \dots B_{i+1}$  se puede extender por reemplazo directo a la solución óptima

$$B_1 \dots B_{i+1}, C_{i+2} \dots C_j$$

lo que concluye la demostración. □

**1.3. El algoritmo.** En base a estas propiedades, podemos considerar el siguiente algoritmo *goloso* como una resolución al problema de la *selección de actividades*.

---

```

1 proc act(A:  $\mathbb{N} \times \mathbb{N}$ )  $\rightarrow$   $\mathbb{N} \times \mathbb{N}$ :
2   ordenar A por tiempo de finalización
3   P  $\leftarrow \emptyset$ 
4   i  $\leftarrow 0$ 
5   para (s, t) en A:
6     si s  $\geq$  i:
7       P  $\leftarrow$  P  $\cup$  {(s, t)}
8       i  $\leftarrow$  t
9   retornar P

```

---

ALGORITMO 1. Pseudocódigo para la *selección de actividades*.

El mismo itera sobre las actividades en  $A$  por orden de finalización. En base a la estrategia golosa, decide incluir, o no, una actividad si y sólo si comienza después de que termine la última actividad que ya se incluyó a la solución, cuyo tiempo de finalización se guarda en la variable  $i$ . Dado que no tiene sentido considerar tiempos negativos, inicializamos  $i$  en 0.

**1.4. Complejidad temporal y espacial.** El comportamiento del algoritmo depende del método de ordenamiento que elijamos y de las características de la estructura subyacente al conjunto  $P$  (en particular, si la inserción de un elemento se puede realizar en tiempo constante).

Respecto al método de ordenamiento, dado que los tiempos de finalización están acotados por  $2n$ , podemos utilizar *counting sort* para garantizar una complejidad de peor caso, tanto temporal como espacial, de orden lineal. Notar que *counting sort* tiene complejidad  $\Theta(m+k)$

donde  $m$  es la cantidad de elementos a ordenar y  $k$  es la diferencia entre el valor máximo y mínimo en el conjunto. Para simplificar el algoritmo, vamos a trabajar con  $k = 2n$  fijo. Luego, el ordenamiento es  $\Theta(n + 2n) = \Theta(n)$ .

Respecto a las características de  $P$ , si se implementa como un arreglo de tamaño  $n$  —dado que una solución óptima tiene a lo sumo esta cantidad de actividades—, sigue que el costo de inserción es constante. Sin embargo, debemos tener cuidado de liberar el espacio excedente luego de obtener un resultado.

De estas observaciones, y el hecho de que, como hay  $n$  actividades, el costo temporal del ciclo es lineal, sigue que tanto la complejidad temporal como espacial de peor caso del algoritmo es  $\Theta(n)$ .

## 2. EVALUACIÓN EMPÍRICA

Para revisar de manera empírica la cota lineal del algoritmo<sup>5</sup>, procedimos a implementarlo en  $C++$  y realizamos una serie de evaluaciones respecto al tiempo de ejecución en función del tamaño de la entrada, para muestras aleatorias de tamaño  $n = 2^k$  para cada  $k$  natural en el rango  $16 \leq k \leq 26$ . Realizamos cada evaluación diez veces para reducir la variación de los resultados y tomamos el promedio aritmético.

El siguiente gráfico describe, en escala  $\log\text{-}\log$  —dada la naturaleza exponencial de los casos de test— la relación entre el tamaño de entrada y el tiempo de ejecución. También, muestra la línea que mejor describe los datos, resultante de aplicar regresión lineal.




FIGURA 1. Tiempo de ejecución del algoritmo de *selección de actividades* en función del tamaño de la entrada, para instancias aleatorias.

<sup>5</sup>Los experimentos y archivos resultantes se pueden encontrar en [./ej-3/experimentacion](#).

La relación lineal es bastante clara. Para asegurarnos, calculamos también el *coeficiente de Pearson*,  $\rho$ , que mide la correlación lineal entre ambas variables, donde  $\rho = 1$  indica una correlación fuerte. El resultado fue  $\rho \approx 0.9997$ .

**2.1. Instancias de interés.** Un análisis del algoritmo indica que lo único que parece alterar el flujo del código<sup>6</sup>, en función de la entrada —en tanto que define instancias más fáciles o difíciles de resolver—, es la cantidad de actividades que son seleccionadas. Donde, por cada actividad seleccionada, se ejecutan dos líneas de código más (en particular, se agrega un elemento más al conjunto de soluciones  $P$ ).

Para probar la diferencia de tiempos posibles entre instancias diferentes bajo este criterio —que tengan cantidades distintas de actividades seleccionables—, realizamos una serie de evaluaciones, siguiendo la metodología de la experimentación anterior, primero con una instancia *comprimida* —en la que la intersección entre todos los intervalos de las actividades de  $A$  es no vacía, por lo que sólo se agrega un elemento al conjunto de soluciones  $P$ — y una instancia de entradas *separadas* —donde la  $i$ -ésima entrada tiene la forma  $(i, i + 1)$ , por lo que se agregan todas las actividades en  $A$  al conjunto de soluciones  $P$ —.

El siguiente gráfico, nuevamente en escala *log-log* por la naturaleza de las muestra, expone los resultados.




FIGURA 2. Tiempo de ejecución de la *selección de actividades* en función del tamaño de entrada  $n$  y la cantidad máxima  $m$  de tareas seleccionables, para *comprimida* — $m = 1$ — y *separadas* — $m = n$ —.

Si bien es verdad que, en las entradas más grandes, las instancias de *separadas* parecen haber tomado un poco más de tiempo, la diferencia no resulta significativa. En promedio, *separadas* fue  $\approx 20.8$  milisegundos más lenta.

<sup>6</sup>Notar que, por la cota fija de  $2n$  que tomamos para *counting sort*, un rango de intervalos menor a  $2n$  no afectará el comportamiento de esta parte del algoritmo. Así también —por sus características—, el mismo no se verá afectado por el ordenamiento inicial de la entrada.